

# 一起学习支持向量机（一）：支持向量机的分类思想

原创 石头 机器学习算法那些事 2018-11-16

## 前言

支持向量机是一种经典的机器学习算法，在小样本数据集的情况下有非常广的应用，我觉得，不懂支持向量机不算是入门机器学习🤔。本篇循序渐进的讲解了支持向量机的分类思想，希望对您有帮助。

## 目录

1. 函数间隔和几何间隔
2. 支持向量机的分类思想
3. 总结

### 1. 函数间隔和几何间隔


为了能够更好的阐述支持向量机的分类思想，需要理解函数间隔和几何间隔的定义。

#### 1. 点到超平面的距离

假设超平面方程：

$$\vec{w}^T \vec{x} + b = 0$$

点  $P(\vec{x}_0, y_0)$  到平面的距离：



$$d = \frac{|\vec{w}^T \vec{x}_0 + b|}{\|\vec{w}\|}, \quad (1.1)$$

由上式可得： $d \geq 0$ ，没有分类信息，而函数间隔和几何间隔不仅包含了距离信息，还包含了分类信息。

#### 2. 函数间隔和几何间隔

对于给定的训练数据集  $T$ ，正样本和负样本分别为 +1 和 -1，我们对式 (1.1) 稍微进行了修改：

(1). 点到平面的距离不作规范化处理, 得:

$$d1 = |\vec{w}^T \vec{x}_0 + b|, \quad (1.2)$$

(2). 去掉绝对值符号, 并乘以标记结果 $y_0$ , 得:

$$d2 = (\vec{w}^T \vec{x}_0 + b) \cdot y_0, \quad (1.3)$$

$d2$ 表达式就是函数间隔的定义, 有两层含义: 大小表示点 $P_0$ 到超平面的距离, 正负表示点 $P_0$ 是否正确分类, 若 $d < 0$ , 分类错误; 反之, 则分类正确。

因此, 我们定义点到超平面的函数间隔为:

$$\hat{\gamma} = y(w \cdot x + b) \quad (1.4)$$

接着定义训练数据集 $T$ 的函数间隔是所有样本点 $(x_i, y_i)$ 的函数间隔的最小值, 即:

$$\hat{\gamma} = \min \hat{\gamma}_i \quad (1.5)$$

其中,

$$\hat{\gamma}_i = y_i(w \cdot x_i + b), i = 1, 2, \dots, N \quad (1.6)$$

但是, 若成比例的增加超平面参数 $w$ 和 $b$ , 超平面没有改变, 但是函数间隔却成比例的增加, 这是不符合理论的, 因此, 需要对函数间隔进行规范化, 得:

$$\tilde{\gamma}_i = \frac{\hat{\gamma}_i}{\|w\|} \quad (1.7)$$

(1.7)式就是几何间隔的定义, 几何间隔的值是确定的。


## 2. 支持向量机的分类思想

### 1. 感知机和logistic回归的分类思想

感知机的损失函数为所有误分类点到超平面的距离之和:

$$L(w, b) = - \sum_{x_i \in M} y_i(w \cdot x_i + b) \quad (2.1)$$

无误分类点时, 损失函数为0, 满足模型分类条件的超平面有无数个, 如下图:



初始超平面为 $l_1$ ，误分类点为红色框，最小化式 (2.1) 有无穷多个满足损失函数为0的超平面，如上图的 $l_2 \sim l_n$ ，然而，**最佳分类超平面只有一个，即支持向量机所对应的超平面。**

假设logistic回归的模型是 $h_\theta(x)$ ，logistic回归的损失函数：

$$L(\theta) = -\sum_{i=1}^N (y_i \log(h_\theta(x_i)) + (1 - y_i) \log(1 - h_\theta(x_i))) \quad (2.2)$$

简单分析 (2.2) 式的分类思想：

(1). 当 $y_i=1$ 时，损失函数简化为：

$$L(\theta) = -\sum_{i=1}^N \log(h_\theta(x_i)) \quad (2.3)$$

若要使损失函数 $L(\theta)$  越小越好，则 $x_i$ 的值越大越好，如下图：





图2.1

当 $x_i$  往箭头方向移动时，损失函数 $L(\theta)$  逐渐变小。

(2). 当 $y_i=0$ 时，损失函数简化为：

$$L(\theta) = -\sum_{i=1}^N \log(1 - h_\theta(x_i))$$


若要使损失函数  $L(\theta)$  越小越好，则  $x_i$  的值越小越好，如下图：



当  $x_i$  往箭头方向移动时，损失函数  $L(\theta)$  逐渐变小。

## 2. 支持向量机的分类思想

支持向量机结合了感知机和logistic回归分类思想，假设训练样本点  $(x_i, y_i)$  到超平面  $H$  的几何间隔为  $\gamma$  ( $\gamma > 0$ )，由上节定义可知，几何间隔是点到超平面最短的距离，如下图的红色直线：



用logistic回归模型分析几何间隔：

$$h(\gamma) = \frac{1}{1 + e^{-\gamma}} = P(1|\gamma)$$

因此，当  $\gamma$  越大时，损失函数越小，结果为正样本的概率也越大。

因此，感知机的分类思想是最大化点到超平面的几何间隔，这个问题可以表示为下面的约束最优化问题：

$$\max_{w,b} \gamma \quad (2.4)$$

$$s.t. \quad y_i \left( \frac{w \cdot x_i + b}{\|w\|} \right) \geq \gamma, \quad i = 1, 2, \dots, N \quad (2.5)$$

根据几何间隔和函数间隔的关系，得几何间隔的约束最优化问题：

$$\max_{w,b} \frac{\gamma}{\|w\|} \quad (2.6)$$

$$s.t. \quad y_i(w \cdot x_i + b) \geq \gamma, \quad i = 1, 2, \dots, N \quad (2.7)$$

函数间隔是样本点到超平面的最短距离，因此，令函数间隔为常数1，那么其他样本点到超平面的距

离都大于1，且最大化  $\frac{1}{\|w\|}$  和最小化  $\frac{1}{2} \|w\|^2$  是等价的。于是就得到下面的最优化问题：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (2.8)$$

$$s.t. \quad y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \quad (2.9)$$

由(2.8)式和(2.9)式，解得最优解 $w^*, b^*$ ，易知最优超平面到正负样本的几何间隔相等（请理解几何间隔的含义，然后仔细回想整个分类过程，就会得到这个结论）。

### 3. 总结

本文结合了感知机和logistic回归的分类思想来推导支持向量机的最优化问题，即最大间隔分离超平面。

#### 参考

李航 《统计学习方法》

#### 推荐阅读文章

线性分类模型（一）：线性判别模型分析

线性分类模型（二）：logistic回归模型分析

浅析感知机学习算法



长按二维码关注

机器学习算法那些事

微信: beautifulife244

砥砺前行 不忘初心