

深入浅出核函数

原创 石头 机器学习算法那些事 2018-11-13

前言

支持向量机是最重要的机器学习算法之一，支持向量机的一个重要特点是通过核函数进行非线性分类。本文深度剖析了核函数的含义，并从该角度去理解线性回归和非线性分类的问题。

目录

- 1、线性回归的核函数表示
- 2、核函数含义解析
- 3、核函数含义理解线性回归
- 4、核函数含义理解非线性分类
- 5、核函数的应用范围
- 6、总结

线性回归的核函数表示

我们先通过构建最优线性回归模型来引出核函数的表达式。

已知 N 个样本数据 $\{x_i, t_i\}$, $i = 1, 2, \dots, N$, 构建最优线性回归模型。

损失函数:

$$J(\vec{w}) = \frac{1}{2} \sum_{n=1}^N \{\vec{w}^T \overrightarrow{\phi(x_n)} - t_n\}^2 + \frac{\lambda}{2} \vec{w}^T \vec{w} \quad (1.1)$$

假设 $\overrightarrow{\phi(x_n)}$ 是 M 维的基函数列向量, $\overrightarrow{\phi(x_n)} = (\phi_0(x_n), \phi_1(x_n), \dots, \phi_{M-1}(x_n))^T$

令 $\frac{\partial J(\vec{w})}{\partial \vec{w}} = 0$, 得:

$$\vec{w} = -\frac{1}{\lambda} \sum_{n=1}^N \{\vec{w}^T \overrightarrow{\phi(x_n)} - t_n\} \overrightarrow{\phi(x_n)} = \sum_{n=1}^N a_n \overrightarrow{\phi(x_n)} = \Phi^T \vec{a} \quad (1.2)$$

其中:

$$\vec{a} = (a_1, a_1, \dots, a_n)^T, a_n = -\frac{1}{\lambda} \{\vec{w}^T \overrightarrow{\phi(x_n)} - t_n\}$$

$$\Phi = \begin{pmatrix} \phi_0(x_1), \phi_1(x_1), \dots, \phi_{M-1}(x_1) \\ \phi_0(x_2), \phi_1(x_2), \dots, \phi_{M-1}(x_2) \\ \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots \\ \phi_0(x_N), \phi_1(x_N), \dots, \phi_{M-1}(x_N) \end{pmatrix}$$

将(1.2)式代入(1.1)式得:

$$J(\vec{a}) = \frac{1}{2} \vec{a}^T K K \vec{a} - \vec{a} K \vec{t} + \frac{1}{2} \vec{t}^T \vec{t} + \frac{\lambda}{2} \vec{a}^T K \vec{a} \quad (1.3)$$

其中 K 为格拉姆矩阵, $K = \Phi^T \Phi$

$$K_{nm} = \overrightarrow{\phi(x_n)}^T \overrightarrow{\phi(x_m)}$$

令 $\frac{\partial J(\vec{a})}{\partial \vec{a}} = 0$, 得

$$\vec{a} = (K + \lambda I_N)^{-1} \vec{t}, \text{ 其中, } I_N \text{ 为单位向量}$$

因此, 对于新的输入变量 x , 目标变量为:

$$y(x) = \vec{w}^T \overrightarrow{\phi(x)} = \vec{a}^T \Phi \overrightarrow{\phi(x)} = \overrightarrow{k(x)}^T (K + \lambda I_N)^{-1} \vec{t} \quad (1.4)$$

其中, $\overrightarrow{k(x)} = (k_1(x), k_2(x), \dots, k_N(x))^T$,

$$k_n(x) = k(x_n, x) \quad (1.5)$$

$$k(x_n, x) = \overrightarrow{\phi(x_n)}^T \overrightarrow{\phi(x)} \quad (1.6)$$

因此, 1.5式就是核函数的表达式, 1.4式就是线性回归模型的核函数对偶表示

总结:

(1) 1.5式就是传说中的核函数方程，核函数方程的展开式有很多种情况，这一节的核函数方程展开式是基函数向量的内积。

(2) 1.4式是线性回归的核函数对偶形式，对偶形式都会包含下面这项：

$$\sum_{n=1}^N k(x_n, x)$$

核函数含义解析

我们用1.5式和1.6式来解析核函数的含义。

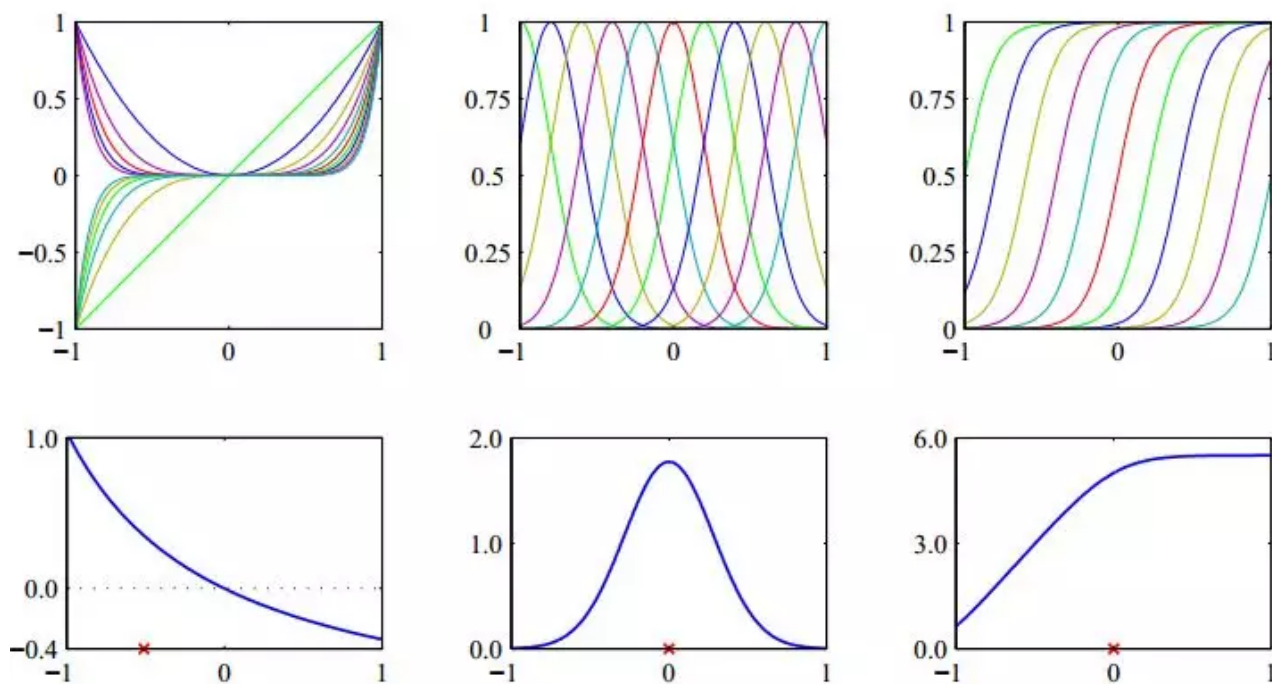
1.5式和1.6式结合，得：

$$k(x, x') = \overrightarrow{\phi(x)}^T \overrightarrow{\phi(x')} = \sum_{i=0}^{M-1} \phi_i(x) \phi_i(x'), \quad \text{其中 } \phi_i(x) \text{ 为基函数}$$

上式表示，先对输入变量映射为特征空间 $\overrightarrow{\phi(x)}$ ，然后在该特征空间下内积。

现在，我们考虑三种常用的基函数，分别为多项式基函数，高斯基函数，S型基函数。

令输入变量 x' 为常数， x' 的值用红色叉号表示，可以画出 x 与 $k(x, x')$ 的关系曲线：



图的第一行为基函数曲线，第二行为 x 与核函数 $k(x, x')$ 的曲线。

由上图可知，核函数 $k(x, x')$ 取得最大值的必要条件是 $x = x'$ ，核函数值的大小可以表示两个输入变量 x 和 x' 的相似度。举例说明这一含义：

如上图第二列，归一化的正态分布在 $x=0$ 具有最大概率，当两个输入变量值都是0时，核函数具有最大值，它们的相似度最高。

如上图第三列，S型函数值表示 $P(y=1|x)$ 的概率，当两个输入变量都是1时，核函数具有最大值，它们的相似度最高。

因此，核函数的含义可以用相似度来解释，若两个输入变量的特征空间 $\overrightarrow{\phi(x)}, \overrightarrow{\phi(x')}$ 都较大，则两个输入变量在该核函数下具有较高的相似度。

核函数含义理解线性回归

为了阅读方便，1.4式预测目标表达式：

$$y(x) = \vec{w}^T \overrightarrow{\phi(x)} = \vec{a}^T \Phi \overrightarrow{\phi(x)} = \overrightarrow{k(x)}^T (K + \lambda I_N)^{-1} \vec{t} \quad (1.4)$$

为了更好的定性分析问题，令 $(K + \lambda I_N)^{-1}$ 为常数 C

1.4式等价于：

$$y(x) = C * (k_1(x), k_2(x), \dots, k_N(x)) * (t_1, t_2, \dots, t_N)^T$$

$$\Rightarrow y(x) = C * \sum_{n=1}^N k(x_n, x) * t_n \quad (3.1)$$


其中 $k(x_n, x)$ 表示核函数，核函数越大，那么相似度越高。

结论

线性回归可以理解成训练目标值的权值相加，权值与核函数成正比，若输入特征与某一训练样本的特征相似度越高，相应的核函数越大，则对应的权值就越大，该训练样本的目标变量对预测目标变量的影响亦越大。

核函数含义理解非线性分类

解决如下图的二分类问题，不同形状表示不同的类。



(1) 显示映射法

特征映射是沟通线性分类和非线性分类的桥梁

首先对特征进行非线性映射

$\vec{\phi} = (\phi_0, \phi_1, \phi_2, \phi_3, \phi_4)^T$, 即特征由二维映射成五维


$$\Rightarrow \vec{\phi} = (x^2, -2x, y^2, -2y, 1)^T$$

$$\text{决策函数: } f(x) = \sum_{i=0}^4 w_i \phi_i = \vec{w}^T * \vec{\phi}$$

$$\text{令 } \vec{w} = (1, 1, 1, 1, 1)^T$$

$$f(x) = (x-1)^2 + (y-1)^2$$

分类效果图如下:



(2) 核函数法

我们知道核函数的含义是相似度，我们考虑用高斯核函数进行分类，高斯核函数用样本的相对距离来表示相似度，若相对距离越小，则相似度越大，反之相似度越小。

高斯核函数的表达式：

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right)$$

其中，输入变量 x 和 z 的相似度是用 x 和 z 的相对距离来衡量

首先用核函数将低维映射成高维空间，然后用线性支持向量机的方法进行分类（后续文章会详细讲支持向量机算法）。

请用核函数法

第二节用显示映射函数的方法说明了核函数的含义，这一节用该方法求决策函数，但是这种方法难点在于定义显示映射函数，而核函数法是隐式的映射特征空间且核函数法计算 $k(x, x')$ 比较容易，因此推荐核函数法作特征的多维映射。

核函数的应用范围

这一节用一句话来概括：凡是有特征内积出现的式子都可以用核函数来代替。

如下图：

$$K(x_i, x_j) \Rightarrow x_i \bullet x_j$$

左边为核函数，右边为内积。

总结

本文详细的解释了核函数的含义——相似度，然后从核函数的角度去理解线性回归和非线性分类，核函数是隐式的特征空间映射，不需要定义特征映射函数。特征内积出现的式子都可以用核函数来代替，因此，核函数在支持向量机的非线性分类具有不可替代的作用。

参考

李航 《统计学习方法》

Christopher M.Bishop <<Pattern Reconition and Machine Learning>>

推荐阅读文章

[深入理解线性回归算法（一）](#)

[线性分类模型（一）：浅谈判别模型分析](#)

■



-END-



长按二维码关注

机器学习算法那些事
微信: beautifulife244

砥砺前行 不忘初心