

局部线性嵌入 (LLE) 原理总结

原创 石头 机器学习算法那些事 2019-03-22

相关文章推荐：

主成分分析 (PCA) 原理总结

奇异值分解 (SVD) 原理总结

scikit-learn中PCA的使用方法

LLE参考资料下载：


链接：

<https://pan.baidu.com/s/1Ht01oCGpUjL7rCX5bAhnYg>

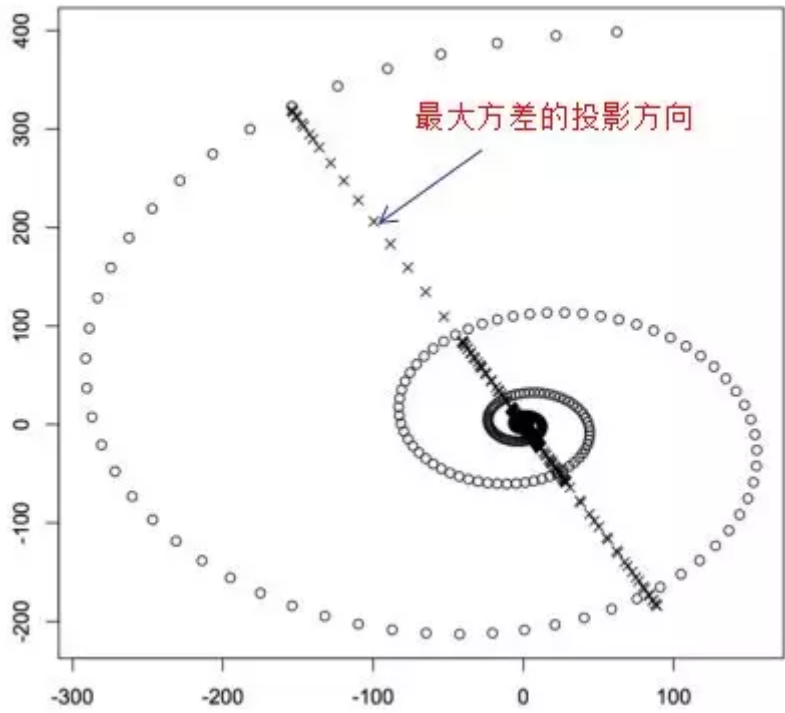
提取码: 62wq

LLE是一种非监督式的降维方法，与PCA降维方法相比，LLE降维后保持了初始样本间的局部关系。PCA是基于投影的最大方差的线性投影，在介绍LLE原理之前，我们首先用几张图看看PCA的降维效果：

对于线性数据，PCA很好的保留了初始样本的结构信息：

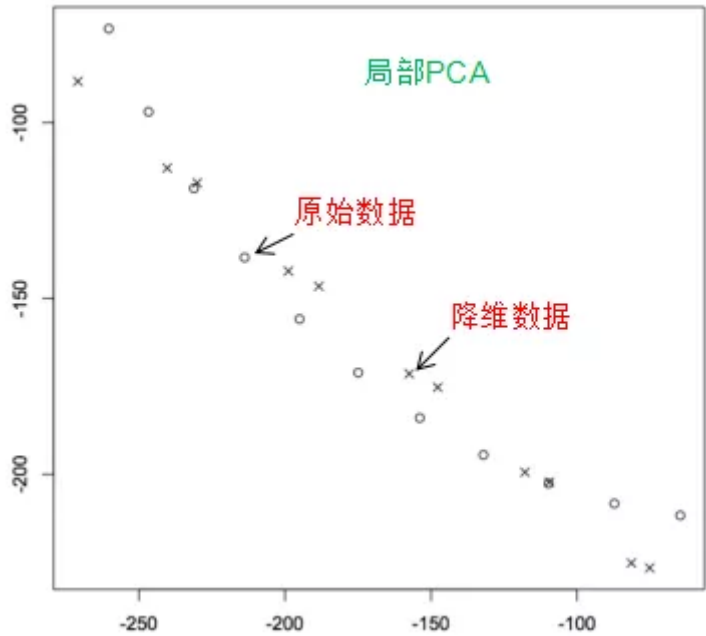


对于流型数据，PCA降维效果如下图：




由上图可知，当初始样本集是一种螺旋形状的非线性结构，经过PCA降维后，结构已经发生了极大的改变，线性降维无法表达螺旋这种非线性结果，因此，PCA对于这类流行数据的降维效果很差。

若我们用积分思想去对这类流行数据进行PCA降维，对流形数据进行分段，每一段运用PCA降维，局部曲线曲度比较小，接近于直线，因此局部PCA可以很好地拟合曲线：



LLE的核心思想是依次对分段数据进行PCA降维，效果图如下：



因此，LLE可以很好的拟合了原始样本集的结构信息。


目录

- 1. LLE算法原理
- 2. LLE算法推导
- 3. LLE算法流程
- 4. K近邻空间大于输入数据的维数D的情况分析
- 5. 小结


1. LLE算法原理

LLE是Locally Linear Embedding的缩写，意思为局部线性嵌入。

局部线性的含义是整个数据集的局部范围内，数据是符合线性的，如下图：



嵌入的含义是降维，LLE的降维思想是不改变原始样本集的结构信息，即不改变对应的样本权重，如下图：



因此，投影前后的样本之间的关系（权重）不变，下面基于LLE思想去推导LLE算法过程：

2. LLE算法推导

推导算法前，我们首先假设样本和权重的矩阵表示：

初始样本集： $X_{D \times N} = [x_1, x_2, \dots, x_N]$

样本的K近邻权重： $W_{K \times N} = [w_1, w_2, \dots, w_N]$

LLE降维后的样本集： $Y_{d \times N} = [y_1, y_2, \dots, y_N]$

算法推导思想：

(1) 根据初始样本集得到局部线性权重W：

$$RSS_i(w) = \sum_{i=1}^N \|x_i - \sum_{j=1}^K w_{ji} x_{ji}\|^2 \quad (1)$$

最小化上式，可得每个样本的K近邻权重，W的定义：

$$W_{K \times N} = (w_1, w_2, \dots, w_N)$$

其中 $w_i = (w_{i1}, w_{i2}, \dots, w_{ik})^T$ 表示样本 x_i 的K近邻权重的列向量， x_{ji} 表示 x_i 的第j个近邻样本， w_{ji} 表示 x_i 的第j个近邻样本的权重，对权重进行归一化：

$$\sum_{j=1}^K w_{ji} = 1$$

(2) 已知K近邻样本权重W，求解LLE降维的d维列向量 y_i ：

$$\Phi(Y) = \sum_{i=1}^N \|y_i - \sum_{j=1}^K w_{ji} y_{ji}\|^2 \quad (2)$$

最小化上式，可得降维后的样本数据集Y：

$$Y_{d \times N} = [y_1, y_2, \dots, y_N]$$

其中 y_i 表示样本降维后的列向量， y_{ji} 表示降维样本 y_i 的第j个K近邻样本。我们对降维后的样本集进行标准化，即降维后的样本特征均值为0，标准差为1，特征间的协方差为0。用下式表示：

$$\begin{aligned} \sum_{i=1}^N y_i &= 0 \\ \frac{1}{N} \sum_{i=1}^N y_i y_i^T &= I_{d \times d} \end{aligned}$$

好了，先停顿一下，看到这里你懂了这些数据集表示的含义了吗？

下面根据推导思想来求解LLE降维后样本集：

Step1:

我们首先通过KNN算法确定多少个邻域样本线性表示某个样本，假设这个值为K，则 x_i 的K近邻点为：

$$N_i = KNN(x_i, K), N_i = [x_{1i}, x_{2i}, \dots, x_{Ki}] \quad (3)$$

Step2:

最小化 (1) 式得到权重系数矩阵W，下面推导求解系数矩阵W的过程：

$$RSS(w_i) = \sum_{i=1}^N \left\| x_i - \sum_{j=1}^K w_{ji} x_{ji} \right\|^2 \quad (1)$$

$$\because \sum_{j=1}^K w_{ji} = 1$$

(1) 式得：

$$\begin{aligned} &\Rightarrow \sum_{i=1}^N \left\| \sum_{j=1}^K w_{ji} x_i - \sum_{j=1}^K w_{ji} x_{ji} \right\|^2 \\ &= \sum_{i=1}^N \left\| \sum_{j=1}^K w_{ji} (x_i - x_{ji}) \right\|^2 \\ &= \sum_{i=1}^N \left\| (X_i - N_i) w_i \right\|^2 \quad (4) \end{aligned}$$

其中 $X_i = \underbrace{[x_i, x_i, \dots, x_i]}_K$ ， N_i 的定义请参考式(3)

假设 \vec{r} 是列向量，那么 $\|\vec{r}\|^2 = \vec{r}^T \vec{r}$

\therefore (4) 式得：

$$\Rightarrow \sum_{i=1}^N w_i^T (X_i - N_i)^T (X_i - N_i) w_i$$

令 $G_i = (X_i - N_i)^T (X_i - N_i)$ ，得：

$$\Rightarrow \sum_{i=1}^N w_i^T G_i w_i \quad (5)$$

权重系数 W 满足约束条件:

$$\sum_{j=1}^K w_{ji} = 1$$

因此用拉格朗日乘子法最小化(5)式, 得:

$$L(w_i, \lambda) = \sum_{i=1}^N w_i^T G_i w_i + \lambda (\mathbf{1}^T w_i) \quad , \text{其中 } \mathbf{1} \text{ 表示 } K \times 1 \text{ 的全为1的列向量, } \mathbf{1} = [1, 1, \dots, 1]_{K \times 1}^T$$

$$\text{令 } \frac{\partial L}{\partial w_i} = 0$$

得:

$$\frac{\partial L}{\partial w_i} = 2G_i w_i - \lambda \mathbf{1}^T = 0$$

$$\Rightarrow w_i = \frac{\lambda}{2} G_i^{-1} \mathbf{1}^T$$

λ 的作用是使 w_i 的元素和为1

$$\therefore w_i = \frac{G_i^{-1} \mathbf{1}}{\mathbf{1}^T G_i^{-1} \mathbf{1}}$$

即求得每个样本的权重系数 W ,

$$W = (w_1, w_2, \dots, w_N)$$

因此求权重系数最关键的步骤是求 G_i 的逆矩阵

Step3:

已知权重系数, 求LLE降维空间, 即最小化下式:

$$\Phi(Y) = \sum_{i=1}^N \left\| y_i - \sum_{j=1}^K w_{ji} y_{ji} \right\|^2 \quad (2)$$

约束条件:

$$\sum_{i=1}^N y_i = 0$$

$$\frac{1}{N} \sum_{i=1}^N y_i y_i^T = I_{d \times d}$$

对于不在 K 近邻范围内的样本, 令该样本与中心样本的权重为零, 因此, 有:

$$w_{k+1,j} = w_{k+2,j} = w_{k+3,j} = \dots = w_{N,j} = 0$$

权重系数满足如下等式:

$$\sum_{j=1}^K w_{ji} = \sum_{j=1}^N w_{ji} = 1$$

令单位向量 $I_{N \times K} = [I_1, I_2, \dots, I_K]$, 权重矩阵 $W_{N \times K} = [w_1, w_2, \dots, w_k]$ 。

因此 (2) 式得:

$$\Phi(Y) = \sum_{i=1}^N \|Y(I_i - w_i)\|^2$$

矩阵 $A = [a_1, a_2, \dots, a_N]$, 有:

$$\sum_{i=1}^N (a_i)^2 = \sum_{i=1}^N a_i^T a_i = \text{Tr}(AA^T)$$

所以:

$$\Phi(Y) = \text{tr}(Y(I - W)(I - W)^T Y^T)$$

约束条件: $YY^T = \sum_{i=1}^N y_i y_i^T = NI_{d \times d}$

令 $M_{N \times N} = (I - W)(I - W)^T$, 用拉格朗日乘子法求 Y :

$$L(Y, u) = YMY^T - u(YY^T - NI_{d \times d})$$

$$\text{令 } \frac{\partial L(Y, u)}{\partial Y} = 2MY^T - 2uY^T = 0$$

$$\Rightarrow MY^T = uY^T$$

所以, Y 的含义其实就是 M 的特征向量, LLE 是从 D 维映射到 d 维, 要求 $\Phi(Y)$ 的最小值, 只要取 M 矩阵最小的 d 个特征值对应的特征向量即可, 特征向量组成矩阵 Y 。

一般取最小的 d 个特征值时, 不考虑最小的特征值。因此取特征值 $d_2 \sim d_{k+1}$ 对应的特征向量 $y_2 \sim y_{k+1}$, 因此矩阵 $Y = [y_2, y_3, \dots, y_{k+1}]$ 。

简单分下为什么不取最小特征值 d_1 对应的特征向量?

$$W^T \vec{e} = \vec{e}$$

$$(W^T - I)\vec{e} = 0$$

$\because \vec{e}$ 是全为1的向量

$$\therefore W^T - I = 0$$

两边转置: $(I - W)^T = 0$

两边同时左乘 $I - W$:

$$(I - W)(I - W)^T = 0$$

$$(I - W)(I - W)^T \vec{e} = 0 \vec{e}$$

所以矩阵M的最小特征值为0，一般不考虑特征值为0的特征向量，因为该特征值并不能反映数据特征。

3. LLE算法流程

1) 确定每个样本的K近邻空间

2) 求协方差矩阵:

$$G_i = (X_i - N_i)^T (X_i - N_i)$$

其中 $X_i = [\underbrace{x_i, x_i, \dots, x_i}_k]$,

$$N_i = [x_{1i}, x_{2i}, \dots, x_{Ki}]$$

3) 根据协方差矩阵 G_i ，求解权重 w_i :

$$w_i = \frac{G_i^{-1} \vec{1}}{\vec{1}^T G_i^{-1} \vec{1}}$$

求每个样本的权重矩阵，得到 W :

$$W = (w_1, w_2, \dots, w_N)$$

4) 求矩阵M的最小d各特征值对应的特征向量 y_i ，矩阵M:

$$M_{N \times N} = (I - W)(I - W)^T$$

其中矩阵 $I_{N \times K}$ 是单位矩阵。

特征向量就是LLE输出的低维样本集矩阵 Y :

$$Y = [y_2, y_3, \dots, y_{k+1}]$$

4. K近邻空间大于输入数据的维数D的情况分析

如果 $K > D$ ，那么用 K 近邻空间的样本线性表示中心样本时，**存在无数个解空间**。用简单的例子来解释这一结论，如方程：

$$\begin{cases} x_1 + x_2 + x_3 = 0 \\ x_2 + x_3 = 0 \end{cases}$$

有无穷个解，三元变量表示 K 近邻数，两个方程表示数据维数 D ，因此 $K > D$ 时，有无穷个解。这种情况使得优化问题无规则 (irregular) 和不适定 (ill-posed)。

解决方法是增加L2正则化，即最小化下式：

$$RSS(w_i) = \sum_{i=1}^N \left\| x_i - \sum_{j=1}^K w_{ji} x_{ji} \right\|^2 + \alpha \sum_{j=1}^K w_{ji}^2$$

其他的求解步骤如上面所写的一样。

5. 小结

LLE 对于流型数据有很好的降维效果，但是流型数据不能是闭合的，且 K 近邻数的选择对结果的影响很大。

参考

<https://blog.csdn.net/scott198510/article/details/76099630>

<https://www.cnblogs.com/pinard/p/6266408.html>

